

# Roteiro completo e entendível de Métodos de Elementos Finitos

Jhuan Cedro

7 de março de 2021

# Sumário

<b>1</b>	<b>Introdução</b>	<b>2</b>
<b>2</b>	<b>Essencial do cálculo?</b>	<b>3</b>
<b>3</b>	<b>Método dos Mínimos Quadrados</b>	<b>4</b>
<b>4</b>	<b>Interpolação</b>	<b>8</b>
4.1	Interpoladores de Lagrange . . . . .	8
<b>5</b>	<b>Problema exemplo I</b>	<b>9</b>
5.1	Formulação fraca . . . . .	9
5.2	Aproximação polinomial . . . . .	9
5.3	Elemento de referência . . . . .	9
<b>6</b>	<b>Métodos de Elementos Finitos</b>	<b>10</b>

# Capítulo 1

## Introdução

.

# Capítulo 2

## Essencial do cálculo?

Só relembrar umas coisas bem básicas e deixar muitas referências

- O que é divergente, gradiente, jacobiana, hessiana;
- Problemas de otimização de funções diferenciáveis;
- Integração por partes, teorema de Green e Gauss;
- (**álgebra linear**) Espaço vetorial, base, distância e norma.

## Capítulo 3

# Método dos Mínimos Quadrados

Os métodos de elementos finitos tem o objetivo de aproximar a solução de um problema diferencial por funções mais simples. Nessa linha, eles acabam recaindo em um método que tem o mesmo princípio, mas sem a parte diferencial. Apresentamos aqui a ideia do método de mínimos quadrados, pois ela será bem útil adiante.

Suponha que você possui um conjunto de dados ... [Achar exemplo e figura \(com  \$N\$  pontos\)](#)




Figura 3.1: ...

Imagine que você queira encontrar uma função que descreve **os seus dados**. Porém, as observações nem sempre são precisas e podem conter erros. Além disso, pode ser que a função que você escolha pra representar seus dados não seja perfeita. Você pode escolher uma reta, uma equação do segundo grau, uma curva exponencial, e por aí vai. O método de mínimos quadrados se propõe a encontrar a função  $f(x)$  que **melhor se aproxime** dos seus dados  $y(x)$ , **dentro de um conjunto de funções** de sua escolha.

Por exemplo, se você quiser encontrar a melhor reta que aproxima  $y(x)$ , você quer escolher  $f(x)$  dentro do conjunto de polinômios de primeiro grau. Qualquer polinômio de primeiro grau pode ser escrito como:

$$p_1(x) = ax + b, \quad \forall a, b \in \mathbb{R}.$$

Portanto, podemos definir o conjunto de todos os polinômios de primeiro grau como:

$$\mathbb{P}_1 = \{p : \mathbb{R} \rightarrow \mathbb{R} \mid p(x) = ax + b, \forall a, b \in \mathbb{R}\} \quad (3.1)$$

Então, nossa missão é encontrar  $a$  e  $b$ , de forma que  $f(x) = p_1(x)$  seja a melhor aproximação possível de  $y(x)$ . Porém, precisamos definir que é ser melhor. Fazemos isso definindo o quanto uma função  $f$  erra ao tentar aproximar  $y$ . Por exemplo, em um ponto  $x_i$  o valor da sua função deveria ser  $y_i$ , mas na verdade é  $f(x_i)$ . Essa diferença entre o real e o aproximado é o que chamamos de erro:

$$\text{erro de } f \text{ no ponto } i = y_i - f(x_i). \quad (3.2)$$

Essa forma de definir erro tem a desvantagem de existirem erros positivos e negativos. Como para nós é tudo erro, o sinal não interessa. Nesse método, consideraremos o erro quadrático, definido por:

$$\text{erro quadrático de } f \text{ no ponto } i = (y_i - f(x_i))^2. \quad (3.3)$$

Definimos a melhor função  $f$  como aquela que tem a menor soma dos erros quadráticos em todos os  $N$  pontos. Assim, temos um problema de **minimização funcional**, onde:

$$f = \text{polinômio } p_1 \text{ que minimize } \sum_{i=1}^N (y_i - p_1(x_i))^2 \quad (3.4)$$

Mais formalmente:

$$f = \underset{p_1 \in \mathbb{P}_1}{\operatorname{argmin}} \sum_{i=1}^N (y_i - p_1(x_i))^2 \quad (3.5)$$

Como sabemos que  $p_1(x) = ax + b$ , e também conhecemos todos os pontos  $x_i$  e  $y_i$ , podemos afirmar que o erro total depende apenas de  $a$  e  $b$ , ou seja:

$$\text{Erro}(a, b) = E(a, b) = \sum_{i=1}^N (y_i - p_1(x_i))^2 = \sum_{i=1}^N (y_i - (ax_i + b))^2 \quad (3.6)$$

Por sorte, sabemos cálculo! Então sabemos que o ponto mínimo da função  $\text{Erro}(a, b)$  ocorre, necessariamente, quando:

$$\frac{\partial E}{\partial a} = 0 \quad \text{e} \quad \frac{\partial E}{\partial b} = 0.$$

Como o erro é um somatório, e sabemos que a derivada da soma é a soma das derivadas, temos:

$$\begin{aligned} \frac{\partial E}{\partial a} &= \frac{\partial}{\partial a} \left[ \sum_{i=1}^N (y_i - (ax_i + b))^2 \right] = \sum_{i=1}^N \frac{\partial}{\partial a} [(y_i - ax_i - b)^2] = \sum_{i=1}^N [2(y_i - ax_i - b)(-x_i)] \\ &= 2 \sum_{i=1}^N [-x_i y_i + ax_i^2 + bx_i] = 0 \quad \longrightarrow \quad a \sum_{i=1}^N x_i^2 + b \sum_{i=1}^N x_i = \sum_{i=1}^N (x_i y_i) \end{aligned} \quad (3.7)$$

$$\frac{\partial E}{\partial a} = \frac{\partial}{\partial a} \left[ \sum_{i=1}^N (y_i - p_1(x_i))^2 \right] = \sum_{i=1}^N \frac{\partial}{\partial a} \left[ (y_i - p_1(x_i))^2 \right] = \sum_{i=1}^N \left[ 2p_1(x_i) \frac{\partial p_1(x_i)}{\partial a} \right] \quad (3.8)$$

$$\begin{aligned} \frac{\partial E}{\partial b} &= \frac{\partial}{\partial b} \left[ \sum_{i=1}^N (y_i - (ax_i + b))^2 \right] = \sum_{i=1}^N \frac{\partial}{\partial b} \left[ (y_i - ax_i - b)^2 \right] = \sum_{i=1}^N \left[ 2(y_i - ax_i - b)(-1) \right] \\ &= 2 \sum_{i=1}^N \left[ -y_i + ax_i + b \right] = 0 \quad \longrightarrow \quad a \sum_{i=1}^N x_i + b \sum_{i=1}^N 1 = \sum_{i=1}^N y_i \end{aligned} \quad (3.9)$$

Juntando (3.8) e (3.9) podemos escrever o sistema matricial:

$$\begin{bmatrix} \sum_{i=1}^N x_i^2 & \sum_{i=1}^N x_i \\ \sum_{i=1}^N x_i & N \end{bmatrix} \begin{bmatrix} a \\ b \end{bmatrix} = \begin{bmatrix} \sum_{i=1}^N x_i y_i \\ \sum_{i=1}^N y_i \end{bmatrix} \quad (3.10)$$

Satisfazer o sistema assim é uma **condição necessária** para que um ponto  $(a, b)$  seja mínimo da função  $E(a, b)$ , mas ainda **não garante** que este ponto seja um mínimo local de  $E$  (menos ainda que seja global). Para garantir que encontramos um ponto  $(a, b)$  que minimize o erro, devemos olhar para as propriedades da matriz hessiana e da convexidade de  $E$ . Para não nos estendermos demais, assumiremos apenas que a solução de (3.10) minimiza o erro  $E$ . Mais detalhes podem ser encontrados em ??.

Note que a escolha da função de erro é fundamental para o funcionamento do método. Poderíamos ter pensado em escolher o erro de  $f$  num ponto  $x_i$  como sendo, por exemplo,  $|y_i - f(x_i)|$ . Contudo, não teríamos uma função diferenciável (a função módulo tem “bicos”) e não poderíamos aplicar essa tática de minimização, baseada em derivadas, que apresentamos.

Só pra garantir, vamos ver a **hessiana**:

$$\begin{aligned} \frac{\partial^2 E}{\partial a^2} &= \frac{\partial}{\partial a} \left[ 2 \sum_{i=1}^N (-x_i y_i + ax_i^2 + bx_i) \right] = 2 \sum_{i=1}^N x_i^2 \\ \frac{\partial}{\partial a} \frac{\partial E}{\partial b} &= \frac{\partial}{\partial b} \frac{\partial E}{\partial a} = \frac{\partial}{\partial b} \left[ 2 \sum_{i=1}^N (-x_i y_i + ax_i^2 + bx_i) \right] = 2 \sum_{i=1}^N x_i \\ \frac{\partial^2 E}{\partial b^2} &= \frac{\partial}{\partial b} \left[ 2 \sum_{i=1}^N (-y_i + ax_i + b) \right] = 2N \end{aligned} \quad (3.11)$$

$$\mathbf{H}_E = 2 \begin{bmatrix} \sum_{i=1}^N x_i^2 & \sum_{i=1}^N x_i \\ \sum_{i=1}^N x_i & N \end{bmatrix} \rightarrow \det \mathbf{H}_E = 2 \left[ N \sum_{i=1}^N x_i^2 + \left( \sum_{i=1}^N x_i \right)^2 \right] \geq 0 \quad (3.12)$$

Caso exista ao menos um ponto  $x_i \neq 0$ , então podemos afirmar que  $\det \mathbf{H}_E > 0$ . Segundo Diva Flemming, se  $\det \mathbf{H}_E > 0$  e  $\frac{\partial^2 E}{\partial a^2}$  em um ponto  $(a, b)$ , então este ponto é um mínimo local de  $E$ . Se  $E$  for convexa ( $\mathbf{H}_E$  é positiva semi-definida), garantimos que esse mínimo é global.

**Essa parte da Hessiana pode ficar de fora, ou ir para algum apêndice. Até porque, se for provar pro caso geral vai ser um inferno.**

**Partiu falar do caso geral?**

- O que são resíduos ponderados?
- O que são métodos de regressão?
- Falar de projeção e espaços



# Capítulo 4

## Interpolação

### 4.1 Interpoladores de Lagrange

# Capítulo 5

## Problema exemplo I

### 5.1 Formulação fraca

O que é projeção e o que é formulação variacional?

### 5.2 Aproximação polinomial

### 5.3 Elemento de referência

Qual o melhor momento pra falar disso? Primeiro dá um exempli e depois estende com jacobiana e tudo mais?

# Capítulo 6

## Métodos de Elementos Finitos

Métodos de elementos finitos são técnicas numéricas para a resolução de equações diferenciais estacionárias. Estas consistem principalmente na discretização do domínio físico do problema em diversos subdomínios (elementos) sobre os quais são obtidas aproximações para a solução do problema ?.

Na Figura 6.1 é mostrado o exemplo de uma discretização de um domínio unidimensional  $\Omega$  em quatro subdomínios  $\Omega_{e_1}$  a  $\Omega_{e_4}$ . Nesta Figura, é representada a solução  $u$  do problema em questão.




Figura 6.1: Exemplo de discretização de um domínio unidimensional  $\Omega = \bigcup_{i=1}^4 \Omega_{e_i}$ , onde  $u$  é a solução analítica do problema e  $u_h$  é a solução aproximada por um método de elementos finitos.

A aproximação de  $u$ , denotada por  $u_h$ , é obtida a partir da combinação linear de funções de uma base definida em cada subdomínio  $\Omega_{e_i}$ . Frequentemente são adotadas funções polinomiais, mais especificamente, bases de Lagrange. No exemplo da Figura 6.1 são mostradas, em azul e laranja, bases do espaço de polinômios lineares.

Os polinômios de uma base de Lagrange de ordem  $p$  são obtidos a partir de  $p + 1$  pontos de referência do domínio  $(x_i, i \in [1, p + 1])$ . A base é constituída por  $p + 1$  polinômios  $\phi_i^p(x)$  definidos por (6.1).

$$\phi_i^p(x) = \prod_{j=1, j \neq i}^{p+1} \frac{x - x_j}{x_i - x_j}, \quad \begin{matrix} x_a \neq x_b \Leftrightarrow a \neq b \\ 1 \leq i, j \leq p + 1 \end{matrix} \quad (6.1)$$

As Figuras 6.2 a 6.4 ilustram as funções de Lagrange para algumas ordens de polinômios. Cabe observar que  $\phi_i^p(x_j)$  é unitário se  $i = j$  e nulo se  $i \neq j$ . Bases de ordens mais altas apresentam maior capacidade de aproximar a solução, possibilitando a melhoria das aproximações pelo que se denomina refinamento  $p$ .




Figura 6.2: Polinômios de Lagrange de ordem  $p = 1$ .




Figura 6.3: Polinômios de Lagrange de ordem  $p = 2$ .

A partir destas discretizações é possível aproximar a solução  $u$  por uma combinação linear de uma base de Lagrange com coeficientes, obtendo-se  $u_h$ :

$$u(x) \approx u^h(x) = \sum_{i=1}^{p+1} \psi_i \phi_i^p(x), \quad \psi_i \in \mathbb{R} \quad (6.2)$$

Os métodos de elementos finitos são obtidos a partir da adoção de uma formulação fraca para a equação diferencial do problema e da discretização da variável de interesse e sua função




Figura 6.4: Polinômios de Lagrange de ordem  $p = 3$ .

de ponderação em cada elemento do domínio. Comumente os modelos recaem em resolução e sistemas de equações. Na formulação apresentada para o problema deste trabalho, obtém-se um equação de autovalores generalizados (Seção ??).